Si nos organizamos, nos enamoramos todos

Data Science y toma de decisiones — en aplicaciones de citas

Gonzalo Barrera Borla

18 de marzo de 2026 — 19:30
MCD10 — Sem. de aplicaciones de ciencia de datos al ámbito privado
Docente: Pablo Mislej — Universidad de San Andrés

¿Quién soy?

Gonzalo Barrera Borla

Lic. en Economía — FCE, UBA

(casi) Mg. en Estadística — FCEyN, UBA

Data Scientist en Sitch

Sitch

- App de dating con matchmaking por **IA**
- Sin swipe: la IA aprende tus preferencias y propone candidatos con **contexto**
- Perfiles revisados por personas reales
- Cuando hay match mutuo, la IA presenta a los dos — y se retira

download.joinsitch.com

Data Science «in the wild»

No basta con predecir

- En la facultad nos enseñan a **estimar** y **predecir**
- En la práctica, hay que **tomar decisiones** con esas predicciones
- La función objetivo suele ser compleja — no es solo «maximizar valor esperado»

No basta con predecir

- En la facultad nos enseñan a **estimar** y **predecir**
- En la práctica, hay que **tomar decisiones** con esas predicciones
- La función objetivo suele ser compleja — no es solo «maximizar valor esperado»

Tres ejemplos de dominios donde esto es evidente:

1. **Adtech**: ¿Qué aviso muestro?
2. **Carreras de caballos**: ¿Por quién apuesto?
3. **Matchmaking**: ¿Qué parejas presento?

Adtech: el problema

Simplificación: 2 clientes compitiendo por el mismo público

- Cliente A: CPC alto ($2.0), CTR moderado (15%)
- Cliente B: CPC bajo ($0.8), CTR alto (25%)
- Ambos tienen presupuesto diario limitado

Objetivo: maximizar ganancia total

$$\max \sum_i \text{cpc}_i \times \text{clicks}_i \quad \text{s.a.} \quad \sum_t \text{cpc}_i \times x_{i,t} \leq B_i$$

- $x_{i,t} \in \{0, 1\}$: ¿se muestra el aviso del cliente i en la impresión t?
- B_i: presupuesto diario del cliente i
- $\text{clicks}_i = \sum_t x_{i,t} \times \text{ctr}_{i,t}$: clics esperados (en valor esperado)

Adtech: ¿qué pasa en la práctica?

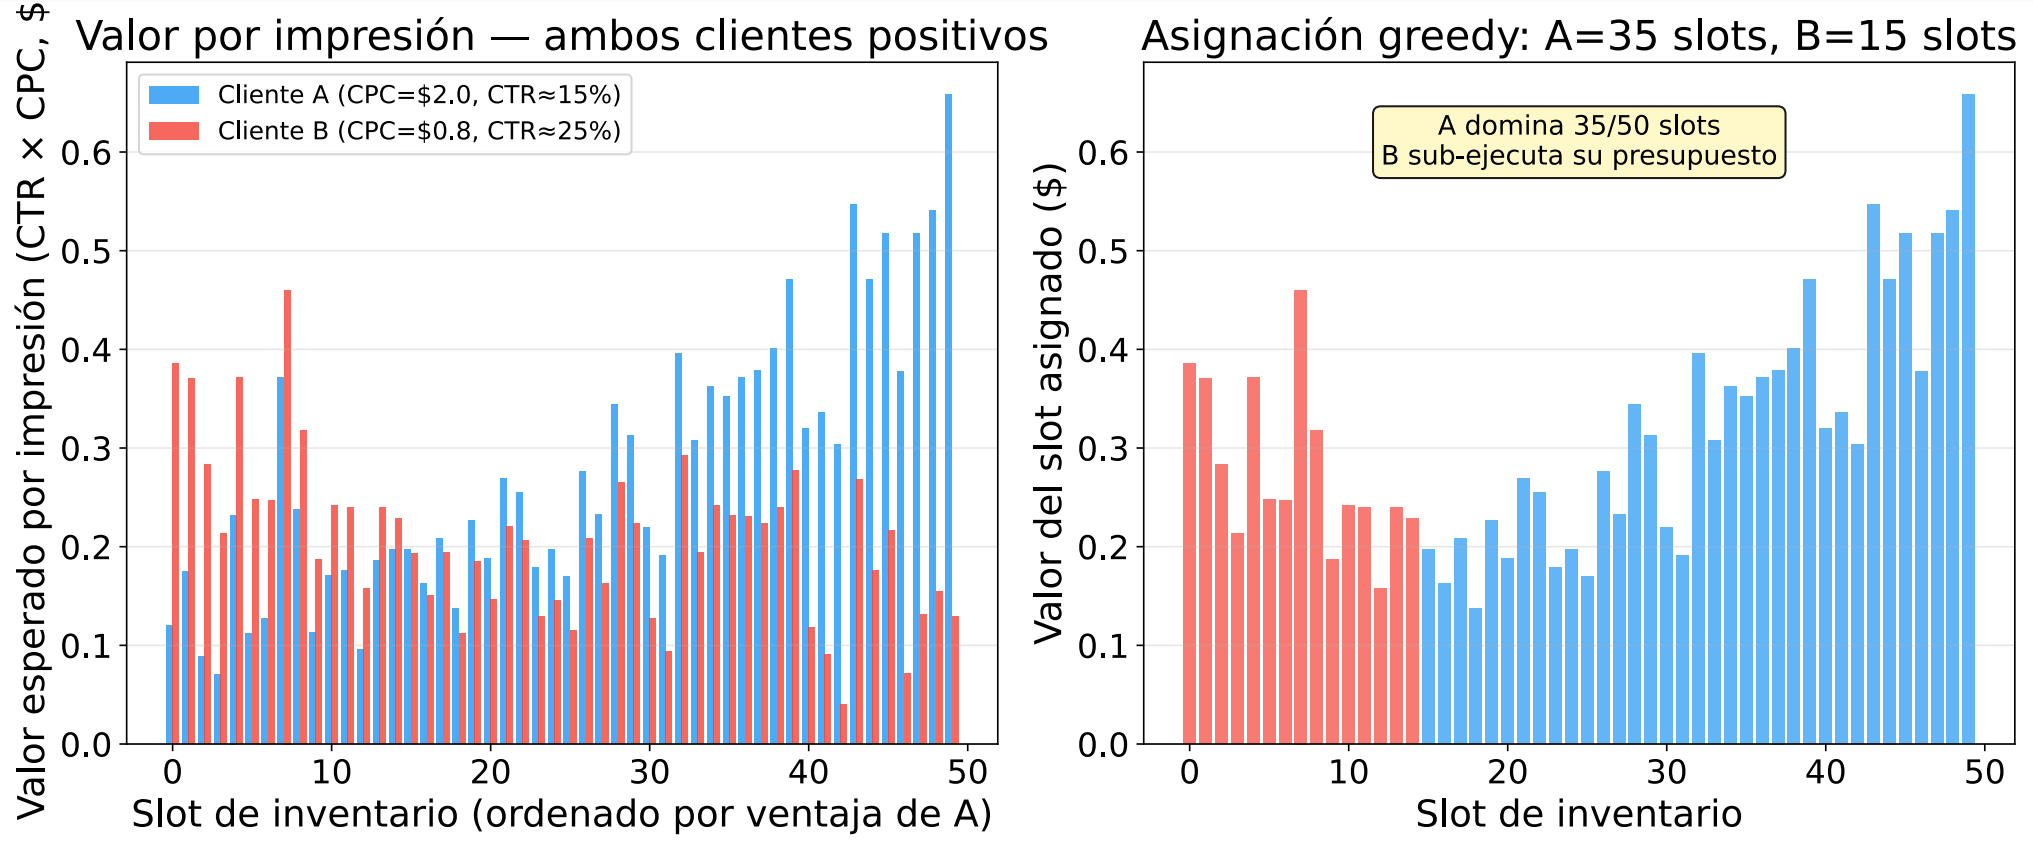

Cuando $\mathrm{ctr}_A \times \mathrm{cpc}_A > \mathrm{ctr}_B \times \mathrm{cpc}_B$ consistentemente, A se lleva casi todo el inventario y B sub-ejecuta su presupuesto.

Adtech: ¿qué pasa en la práctica?

El problema general de bidding óptimo bajo restricciones de presupuesto tiene solución via dualidad de Lagrange (Pita, 2019).

Carreras de caballos: Kelly Criterion

La fracción óptima maximiza el crecimiento logarítmico esperado del capital (Kelly, 1956):

$$K = \frac{\text{ventaja}}{\text{dividendo} - 1} \quad \text{donde} \quad \text{ventaja} = c \times \text{dividendo} - 1$$

- K: fracción del capital a apostar ($K < 0$ → no apostar)
- c: probabilidad estimada de ganar (nuestro modelo)
- dividendo: pago bruto por \$1 apostado (incluye la apuesta)
- $\text{ventaja} < 0$: juego desfavorable; $= 0$: juego justo; > 0: apostar K

Carreras de caballos: Kelly Criterion

La fracción óptima maximiza el crecimiento logarítmico esperado del capital (Kelly, 1956):

$$K = \frac{\text{ventaja}}{\text{dividendo} - 1} \quad \text{donde} \quad \text{ventaja} = c \times \text{dividendo} - 1$$

- K: fracción del capital a apostar ($K < 0$ → no apostar)
- c: probabilidad estimada de ganar (nuestro modelo)
- dividendo: pago bruto por \$1 apostado (incluye la apuesta)
- $\text{ventaja} < 0$: juego desfavorable; $= 0$: juego justo; > 0: apostar K

Advertencia (Benter, 1994): sobreestimar c desplaza K hacia arriba — apostar demasiado puede causar crecimiento negativo del capital.

Carreras: consecuencias a largo plazo

Kelly maximiza la tasa de crecimiento logarítmico esperada por apuesta:

$$G(K) = c \cdot \ln(1 + (\text{dividendo} - 1) \cdot K) + (1 - c) \cdot \ln(1 - K)$$

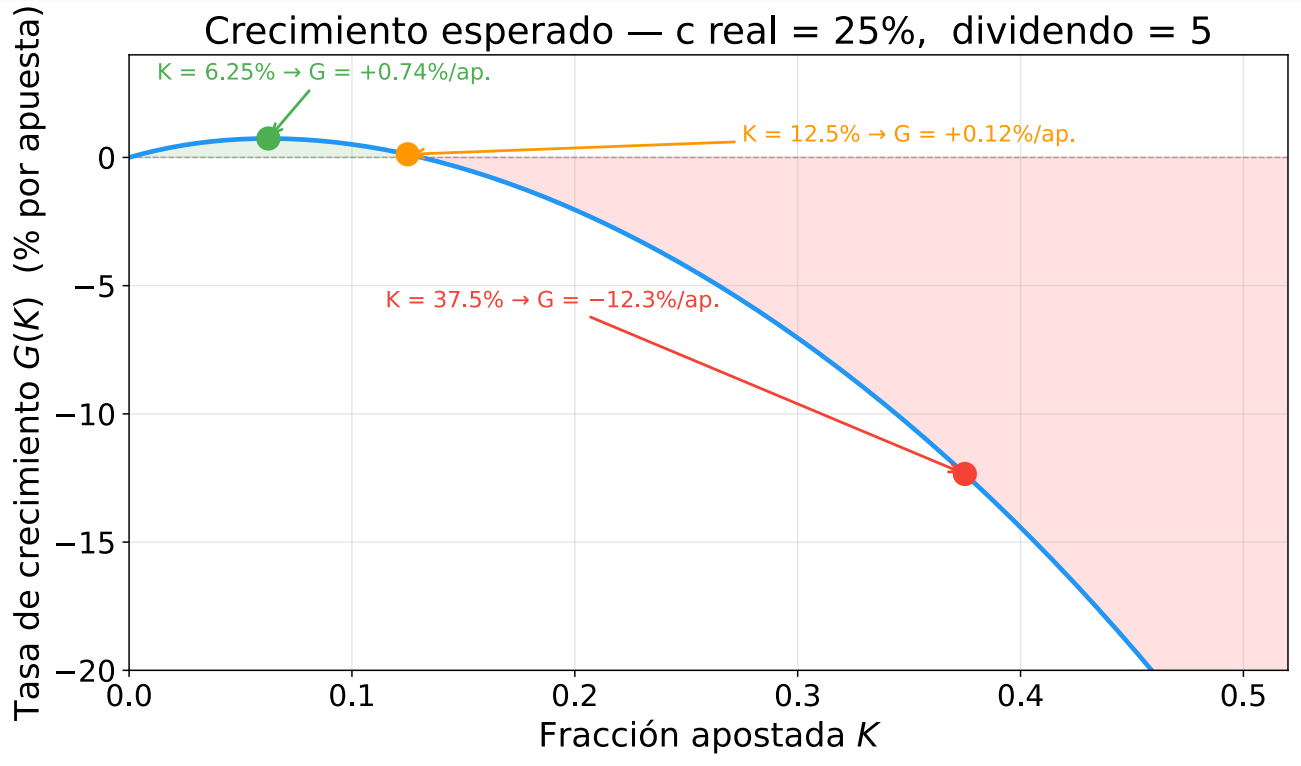

K	c est.	G/ ap.	×200 ap.
6.25%	25%	+0.74%	×4.4
12.5%	30%	+0.12%	×1.3
37.5%	50%	−12.3%	ruina

c real = 25%, dividendo = 5

Matchmaking

El problema del matchmaking

- Plataforma de dating: hay que decidir qué perfiles mostrarle a cada usuario
- Podemos estimar $P(A \to B)$: probabilidad de que A apruebe a B
- Queremos estimar $P(A \leftrightarrow B)$: probabilidad de *match mutuo*

El problema del matchmaking

- Plataforma de dating: hay que decidir qué perfiles mostrarle a cada usuario
- Podemos estimar $P(A \to B)$: probabilidad de que A apruebe a B
- Queremos estimar $P(A \leftrightarrow B)$: probabilidad de *match mutuo*

El dilema: todos quieren a Brad Pitt / Penélope Cruz...

...pero BP/PC no van a querer a todos.

Probabilidades direccionales vs. mutuas

La probabilidad mutua real tiene un término de correlación: la gente que «ofrece» lo que otros buscan, tiende a «buscar» cosas similares.

$$P(A \leftrightarrow B) \neq P(A \rightarrow B) \times P(B \rightarrow A)$$

Probabilidades direccionales vs. mutuas

La probabilidad mutua real tiene un término de correlación: la gente que «ofrece» lo que otros buscan, tiende a «buscar» cosas similares.

$$P(A \leftrightarrow B) \neq P(A \rightarrow B) \times P(B \rightarrow A)$$

Pero estimar $P(A \leftrightarrow B)$ es más difícil que sólo $P(A \rightarrow B)$, así que podemos asumir

$$P(A \leftrightarrow B) \approx P(A \rightarrow B) \times P(B \rightarrow A)$$

Probabilidades direccionales vs. mutuas

La probabilidad mutua real tiene un término de correlación: la gente que «ofrece» lo que otros buscan, tiende a «buscar» cosas similares.

$$P(A \leftrightarrow B) \neq P(A \rightarrow B) \times P(B \rightarrow A)$$

Pero estimar $P(A \leftrightarrow B)$ es más difícil que sólo $P(A \rightarrow B)$, así que podemos asumir

$$P(A \leftrightarrow B) \approx P(A \rightarrow B) \times P(B \rightarrow A)$$

Y estimar probabilidades condicionales con un único estimador:

$$P(A \leftrightarrow B \mid A \rightarrow B) = P(B \rightarrow A)$$

Probabilidades direccionales vs. mutuas

Cuando hay que tomar *decisiones* con el modelo, esta interpretabilidad es muy útil...

Probabilidades direccionales vs. mutuas

Cuando hay que tomar *decisiones* con el modelo, esta interpretabilidad es muy útil... ¡aunque sea incorrecta!.

«All models are wrong, but some are useful.» — Box (Box, 1976)

Gale-Shapley: Stable Matching

Algoritmo clásico (Gale & Shapley, 1962); Nobel de Economía 2012 (Shapley & Roth)

1. Cada A propone a su candidata favorita libre
2. Cada B acepta *provisoriamente* al mejor proponente; rechaza al resto
3. Los rechazados proponen a su siguiente candidata
4. Repetir hasta que nadie quede sin pareja

Garantiza **estabilidad**: ningún par rechazado se preferiría mutuamente al par asignado.

Gale-Shapley: Stable Matching

Algoritmo clásico (Gale & Shapley, 1962); Nobel de Economía 2012 (Shapley & Roth)

1. Cada A propone a su candidata favorita libre
2. Cada B acepta *provisoriamente* al mejor proponente; rechaza al resto
3. Los rechazados proponen a su siguiente candidata
4. Repetir hasta que nadie quede sin pareja

Garantiza **estabilidad**: ningún par rechazado se preferiría mutuamente al par asignado.

Problema en dating:

- Requiere «aprobar temporariamente» candidatos — no aplica
- Optimiza estabilidad, no bienestar global
- El matching estable puede ser muy desigual

Greedy Matching

- Ordenar aristas por $P(A \leftrightarrow B)$ descendente
- Agregar si ambos nodos están libres
- Garantiza $\geq \frac{1}{2}$ del óptimo (*1/2-aproximación*)

Greedy Matching

- Ordenar aristas por $P(A \leftrightarrow B)$ descendente
- Agregar si ambos nodos están libres
- Garantiza $\geq \frac{1}{2}$ del óptimo (*1/2-aproximación*)

Simple e intuitivo, pero puede «gastar» nodos muy demandados en pares buenos--pero-no-óptimos

Maximum Weight Matching

- Grafo completo ponderado: peso de cada arista = $P(A \leftrightarrow B)$
- Encontrar el matching que maximiza la suma total de pesos

Maximum Weight Matching

- Grafo completo ponderado: peso de cada arista = $P(A \leftrightarrow B)$
- Encontrar el matching que maximiza la suma total de pesos

Ventaja: maximiza bienestar global

Insight contraintuitivo: el matching óptimo global puede NO incluir el par con mayor probabilidad individual

Fuerza bruta con `scipy.minimize`

- Formulación genérica: optimización combinatoria relajada
- Flexible — se puede cambiar la función objetivo fácilmente
- Límite de iteraciones (≈ 1000) para que sea práctico

Fuerza bruta con `scipy.minimize`

- Formulación genérica: optimización combinatoria relajada
- Flexible — se puede cambiar la función objetivo fácilmente
- Límite de iteraciones (≈ 1000) para que sea práctico

Trade-off: se acerca al óptimo pero no lo garantiza, y es más lento

Comparación de enfoques

Algoritmo	Optimiza	Óptimo?	Práctico?
Gale-Shapley	Estabilidad	Sí (estab.)	Difícil en dating
Greedy	Bienestar local	$\geq \frac{1}{2}$ óptimo	Sí, muy rápido
Max Weight	Bienestar global	Sí	Sí
Fuerza bruta	Configurable	Aprox.	Lento

Comparación de enfoques

Algoritmo	Optimiza	Óptimo?	Práctico?
Gale-Shapley	Estabilidad	Sí (estab.)	Difícil en dating
Greedy	Bienestar local	$\geq \frac{1}{2}$ óptimo	Sí, muy rápido
Max Weight	Bienestar global	Sí	Sí
Fuerza bruta	Configurable	Aprox.	Lento

Vamos al código...

Resultados

Datos sintéticos

- 500 usuarios, 6 dimensiones (belleza, poder adq., extroversión, intelectualidad, aventura, romanticismo)
- Características con norma variable — algunos tienen «más de todo» ($r_{\text{norma}} = 0.92$ con atractivo recibido)
- Preferencias normalizadas (dirección pura) con componente de atractivo universal
- AUC ≈ 0.74 con Logistic Regression y Gradient Boosted Trees

Comparación principal (500 usuarios)

Algoritmo	Pares	Peso	Tiempo	% óptimo
Gale-Shapley	250	70.8	4ms	92.2%
Greedy	250	72.9	26ms	94.9%
Max Weight	250	76.8	12.3s	100%
Scipy bipartito	250	76.8	3ms	100%

Comparación completa (30 usuarios)

Max Weight, Scipy y Fuerza bruta coinciden (todos óptimos); GS pierde 6%.

Algoritmo	Pares	Peso	Tiempo	% óptimo
Gale-Shapley	15	2.600	< 0.1ms	94.1%
Greedy	15	2.752	< 0.1ms	99.6%
Max Weight	15	2.763	3ms	100%
Scipy bipartito	15	2.763	< 0.1ms	100%
Fuerza bruta	15	2.763	2.1s	100%

Matchings en el grafo — Gale-Shapley

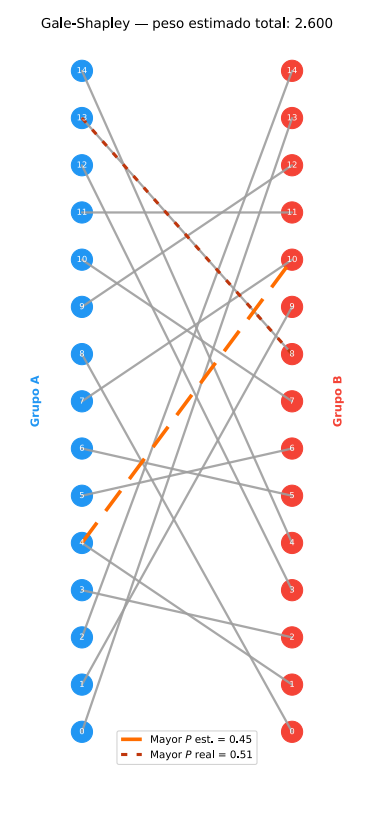

Matchings en el grafo — Greedy

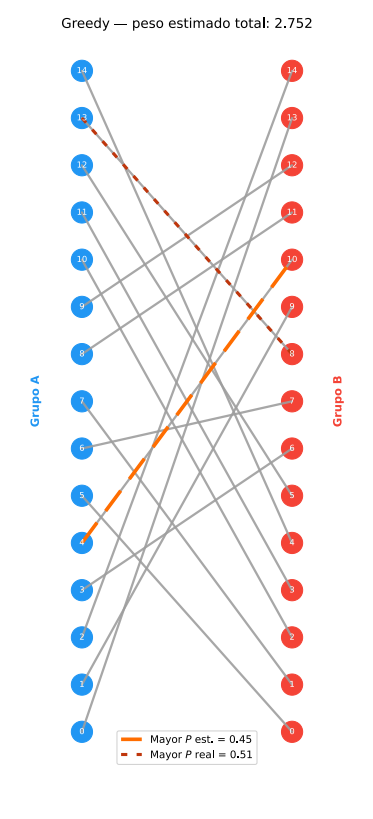

Matchings en el grafo — Max Weight

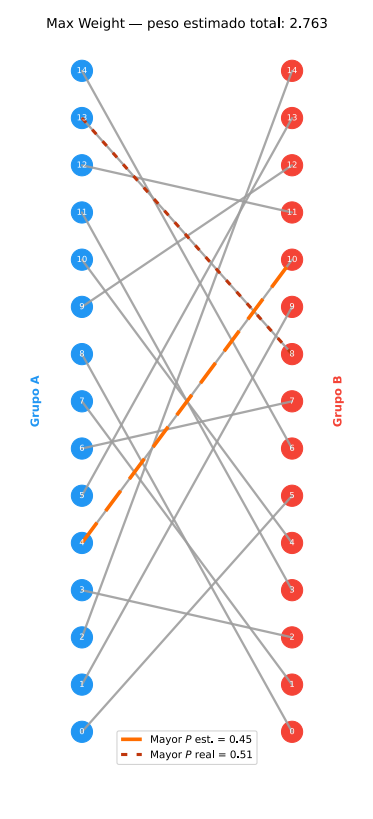

Predicciones vs. Realidad

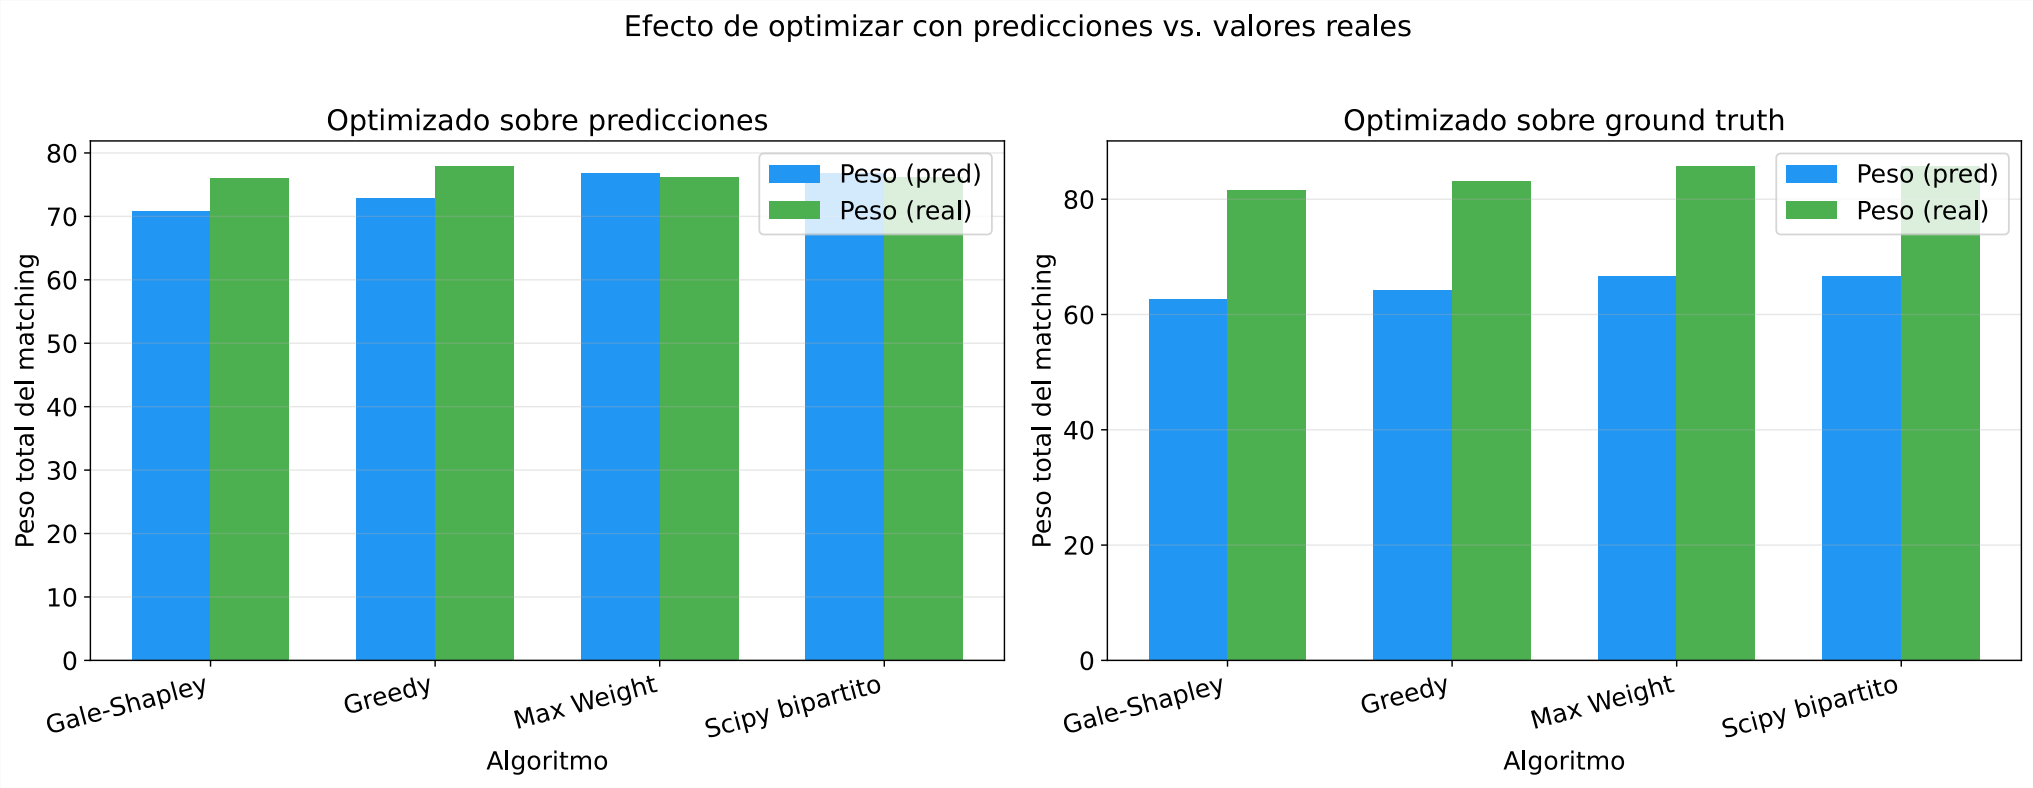

Predicciones vs. Realidad — Pérdida

Con 500 usuarios (grafo bipartito, heterosexual):

- Gale-Shapley: pierde 7% de valor real
- Greedy: pierde 6%
- Max Weight / Scipy: pierde 11%

Predicciones vs. Realidad — Pérdida

Con 500 usuarios (grafo bipartito, heterosexual):

- Gale-Shapley: pierde 7% de valor real
- Greedy: pierde 6%
- Max Weight / Scipy: pierde 11%

Paradoja: el óptimo global es el más frágil ante estimaciones imperfectas.

Insights principales

1. El matching que maximiza el bienestar global puede dejar afuera al par con mayor probabilidad individual.
2. Los algoritmos más «ambiciosos» son más frágiles ante errores de estimación.

Insights principales

1. El matching que maximiza el bienestar global puede dejar afuera al par con mayor probabilidad individual.
2. Los algoritmos más «ambiciosos» son más frágiles ante errores de estimación.

Esto es la esencia de la toma de decisiones en data science: optimizar el sistema completo, no cada componente por separado — pero siendo consciente de la calidad de nuestras estimaciones.

¡Muchas gracias!

@capitantoto

github.com/capitantoto

gonzalo-barrera-borla

Referencias

Bibliografía

Benter, W. (1994). Computer Based Horse Race Handicapping and Wagering Systems: A Report. En D. B. Hausch, V. S. Y. Lo, & W. T. Ziemba (eds.), *Efficiency of Racetrack Betting Markets: Efficiency of Racetrack Betting Markets* (pp. 183-198). Academic Press.

Box, G. E. P. (1976). Science and Statistics. *Journal of the American Statistical Association*, *71*(356), 791-799. https://doi.org/10.1080/01621459.1976.10480949

Gale, D., & Shapley, L. S. (1962). College Admissions and the Stability of Marriage. *The American Mathematical Monthly*, *69*(1), 9-15. https://doi.org/10.1080/00029890.1962.11989827

Kelly, J. L. (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, *35*(4), 917-926. https://doi.org/10.1002/j.1538--7305.1956.tb03809.x

Pita, C. (2019). Optimal bidding: a dual approach. *Proceedings of the 25th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 1-6. http://papers.adkdd.org/2019/papers/adkdd19-pita-optimal.pdf