Si nos organizamos, nos enamoramos todos

Data Science y toma de decisiones — en aplicaciones de citas

Gonzalo Barrera Borla

18 de marzo de 2026 — 19:30
MCD10 — Sem. de aplicaciones de ciencia de datos al ámbito privado
Docente: Pablo Mislej — Universidad de San Andrés

¿Quién soy?

Gonzalo Barrera Borla

Lic. en Economía — FCE, UBA

(casi) Mg. en Estadística — FCEyN, UBA

Data Scientist en Sitch

Sitch

- App de dating con matchmaking por IA
- Sin swipe: la IA aprende tus preferencias y propone candidatos con contexto
- Perfiles revisados por personas reales
- Cuando hay match mutuo, la IA presenta a los dos — y se retira

download.joinsitch.com

Data Science «in the wild»

No basta con predecir

- En la facultad nos enseñan a **estimar** y **predecir**
- En la práctica, hay que **tomar decisiones** con esas predicciones
- La función objetivo suele ser compleja — no es solo «maximizar valor esperado»

Tres ejemplos de dominios donde esto es evidente:

1. **Adtech**: ¿Qué aviso muestro?
2. **Carreras de caballos**: ¿Por quién apuesto?
3. **Matchmaking**: ¿Qué parejas presento?

Adtech: el problema

Simplificación: 2 clientes compitiendo por el mismo público

- Cliente A: CPC alto ($2.0), CTR moderado (15%)
- Cliente B: CPC bajo ($0.8), CTR alto (25%)
- Ambos tienen presupuesto diario limitado

Objetivo: maximizar ganancia total

$$\max \sum_i \text{cpc}_i \times \text{clicks}_i \quad \text{s.a.} \quad \sum_t \text{cpc}_i \times x_{i,t} \leq B_i$$

- $x_{i,t} \in \{0, 1\}$: ¿se muestra el aviso del cliente i en la impresión t?
- B_i: presupuesto diario del cliente i
- $\text{clicks}_i = \sum_t x_{i,t} \times \text{ctr}_{i,t}$: clics esperados (en valor esperado)

Adtech: ¿qué pasa en la práctica?

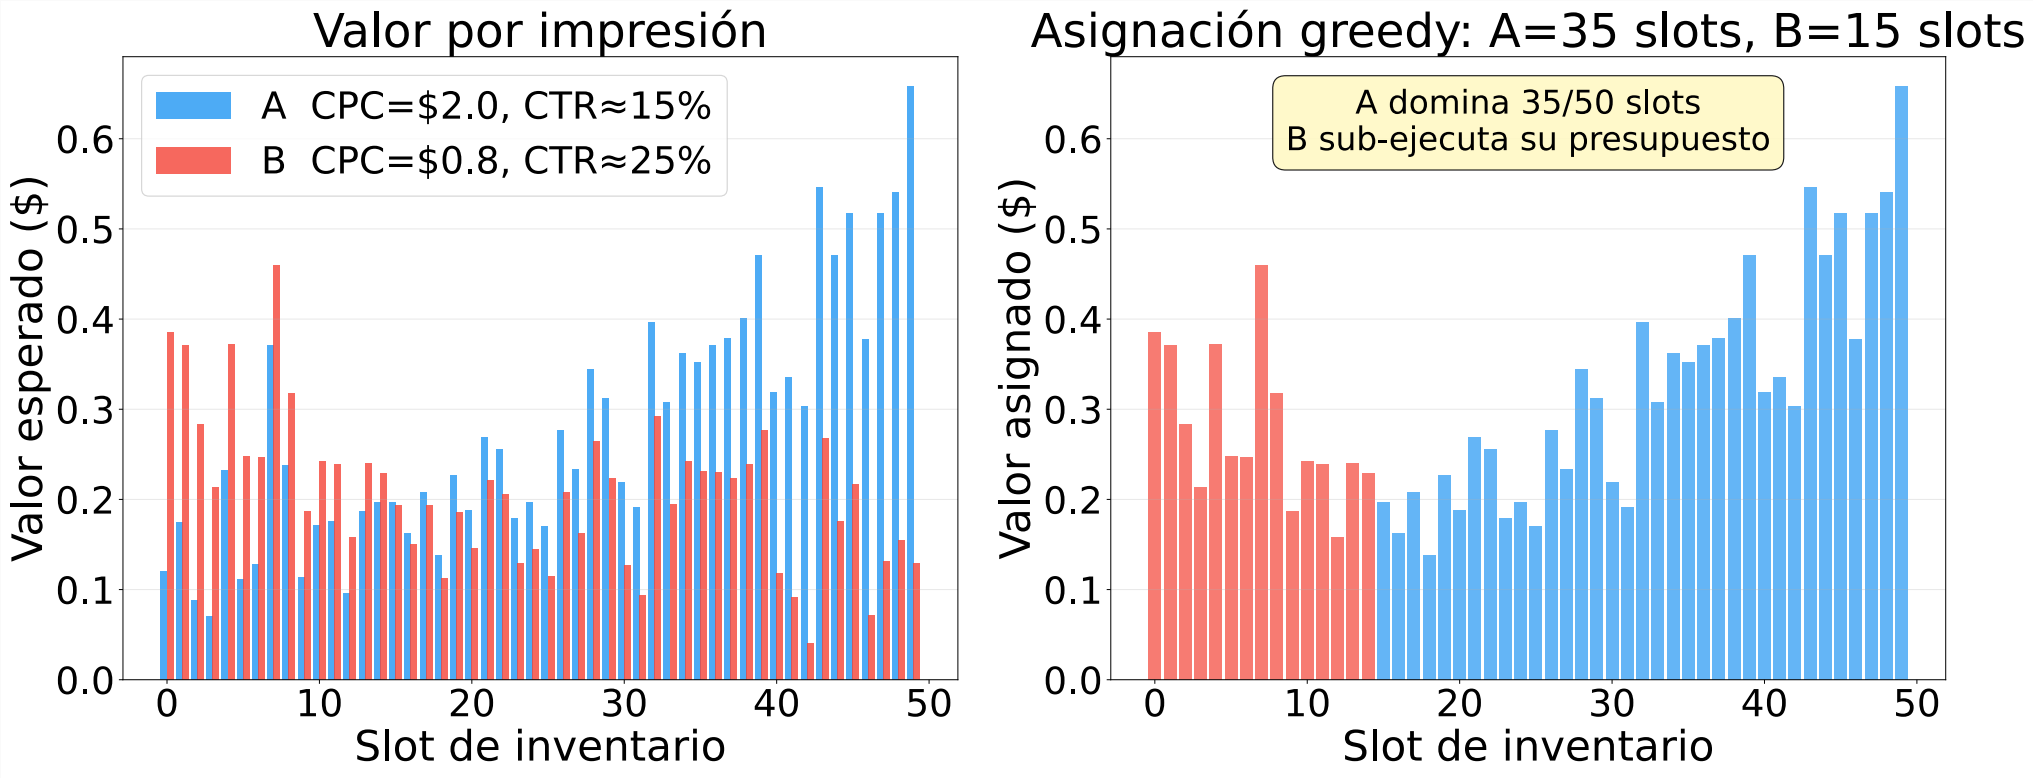

Adtech: ¿qué pasa en la práctica?

Cuando $\mathrm{ctr}_A \times \mathrm{cpc}_A > \mathrm{ctr}_B \times \mathrm{cpc}_B$ consistentemente, A se lleva casi todo el inventario y B sub-ejecuta su presupuesto.

El problema general de bidding óptimo bajo restricciones de presupuesto tiene solución via dualidad de Lagrange (Pita, 2019).

Carreras de caballos: Kelly Criterion

La fracción óptima maximiza el crecimiento logarítmico esperado del capital (Kelly, 1956):

$$K = \frac{\text{ventaja}}{\text{dividendo} - 1} \quad \text{donde} \quad \text{ventaja} = c \times \text{dividendo} - 1$$

- K: fracción del capital a apostar ($K < 0$ → no apostar)
- c: probabilidad estimada de ganar (nuestro modelo)
- dividendo: pago bruto por \$1 apostado (incluye la apuesta)
- $\text{ventaja} < 0$: juego desfavorable; $= 0$: juego justo; > 0: apostar K

Advertencia (Benter, 1994): sobreestimar c desplaza K hacia arriba — apostar demasiado puede causar crecimiento negativo del capital.

Carreras: consecuencias a largo plazo

Kelly maximiza la **tasa de crecimiento logarítmico esperada** por apuesta:

$$G(K) = c \cdot \ln(1 + (\text{dividendo} - 1) \cdot K) + (1 - c) \cdot \ln(1 - K)$$

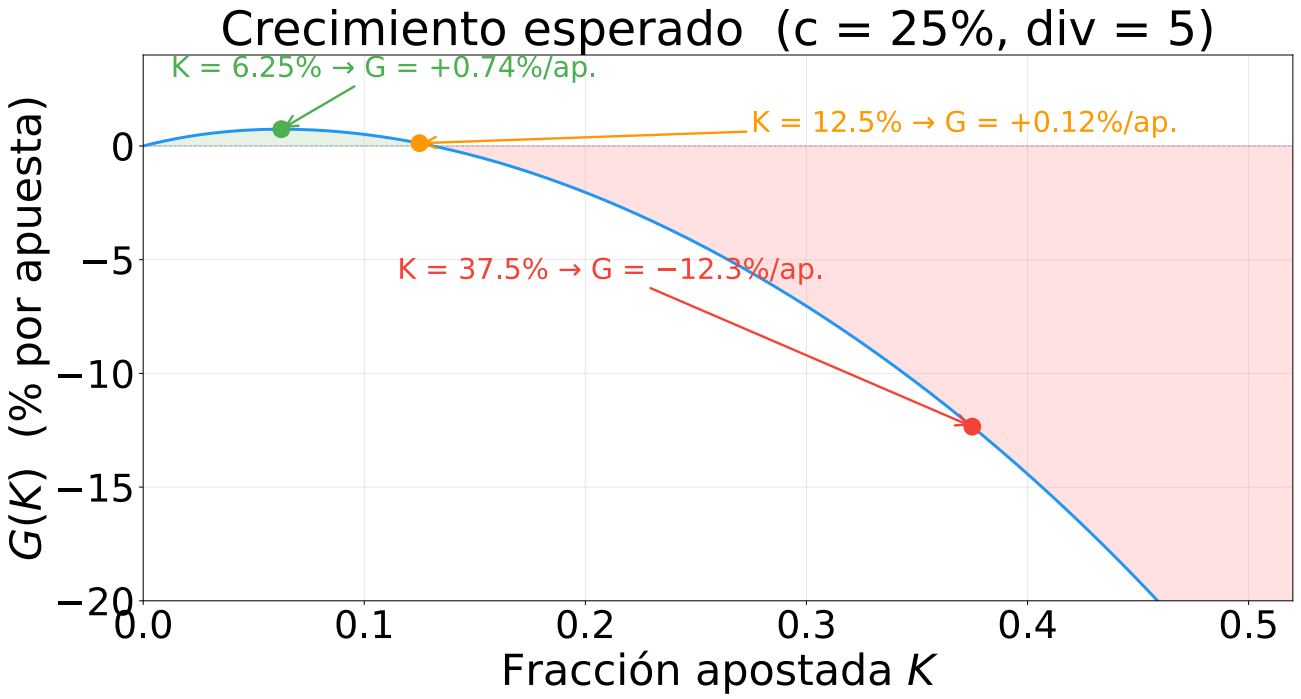

K	c est.	G/ ap.	×200 ap.
6.25%	25%	+0.74%	×4.4
12.5%	30%	+0.12%	×1.3
37.5%	50%	−12.3%	ruina

c real = 25%, dividendo = 5

Matchmaking

El problema del matchmaking

Hay que decidir qué perfiles mostrarle a cada usuario *cada día*.

Es un problema iterado:

- el estado de hoy depende del estado de ayer.
- no es *tan* importante resolverlo «de una» (*one-shot it*)

Múltiples objetivos divergentes:

- Maximizar «engagement» de los usuarios ($\Longrightarrow$ mostrar candidatos hegemónicos)
- Maximizar parejas formadas ($\Longrightarrow$ mostrar candidatos realistas)
- Maximizar crecimiento ($\Longrightarrow$ no cobrar/modelo «freemium»)
- Maximizar ingreso bruto/neto ($\Longrightarrow$ «paywall»)

El problema del matchmaking

- Queremos estimar $P(A \leftrightarrow B)$: probabilidad de *match mutuo*
- Podemos estimar $P(A \rightarrow B)$: probabilidad de que A apruebe a B

Dilema: las probabilidades son asimétricas.

Todos quieren a Brad Pitt / Penélope Cruz ... pero ellos no quieren a todos.

Probabilidades direccionales vs. mutuas

La probabilidad mutua real tiene un término de correlación: la gente que «ofrece» lo que otros buscan, tiende a «buscar» cosas similares.

$$P(A \leftrightarrow B) \neq P(A \rightarrow B) \times P(B \rightarrow A)$$

Pero estimar $P(A \leftrightarrow B)$ es más difícil que sólo $P(A \rightarrow B)$, así que podemos asumir

$$P(A \leftrightarrow B) \approx P(A \rightarrow B) \times P(B \rightarrow A)$$

Y estimar probabilidades condicionales con un único estimador:

$$P(A \leftrightarrow B \mid A \rightarrow B) = P(B \rightarrow A)$$

Probabilidades direccionales vs. mutuas

Cuando hay que tomar *decisiones* con el modelo, esta interpretabilidad es muy útil... ¡aunque sea incorrecta!.

«All models are wrong, but some are useful.» — Box (Box, 1976)

Gale-Shapley: Stable Matching

Algoritmo clásico (Gale & Shapley, 1962); Nobel de Economía 2012 (Shapley & Roth)

1. Cada A propone a su candidata favorita libre
2. Cada B acepta *provisoriamente* al mejor proponente; rechaza al resto
3. Los rechazados proponen a su siguiente candidata
4. Repetir hasta que nadie quede sin pareja

Garantiza **estabilidad**: ningún par rechazado se preferiría mutuamente al par asignado.

Problema en dating:

- Requiere «aprobar temporariamente» candidatos — no aplica
- Optimiza estabilidad, no bienestar global
- El matching estable puede ser muy desigual

  El lado que propone obtiene su mejor pareja estable posible; el que recibe, su peor.

Greedy Matching

1. Ordenar aristas por $P(A \leftrightarrow B)$ descendente
2. Agregar si ambos nodos están libres
3. Garantiza en teoría $\geq \frac{1}{2}$ del óptimo (*1/2-aproximación*)[1]

Simple e intuitivo, pero puede «gastar» nodos muy demandados en pares buenos--pero-no-óptimos

[1] pero en la práctica suele ser mucho mejor.

Maximum Weight Matching

- Grafo completo ponderado: peso de cada arista = $P(A \leftrightarrow B)$
- Encontrar el matching que maximiza la suma total de pesos

Ventaja: maximiza bienestar global

Insight contraintuitivo: el matching óptimo global puede NO incluir el par con mayor probabilidad individual

En grafos bipartitos: algoritmo húngaro (Kuhn, 1955) — O(n^3), exacto.
En grafos generales: blossom de Edmonds (más lento, no necesario aquí).

Fuerza bruta con `scipy.minimize`

- Formulación genérica: optimización combinatoria relajada
- Flexible — se puede cambiar la función objetivo fácilmente
- Pocas iteraciones (50–100 suelen bastar), pero **cada iteración es costosa**

Trade-off: se acerca al óptimo pero no lo garantiza, y es más lento

¿Por qué no simplemente enumerar todos los matchings posibles? Para $n = 500$ usuarios por grupo:

Método	Operaciones	Factible?
Húngaro	$500^3 \approx 1.25 \times 10^8$	Sí — segundos
Exhaustivo	$500! \approx 10^{\{1134\}}$	No — el universo tiene $\approx 10^{\{80\}}$ átomos

Comparación de enfoques

Algoritmo	Optimiza	Óptimo?	Práctico?
Gale-Shapley	Estabilidad	Sí (estab.)	Difícil en dating
Greedy	Bienestar local	$\geq \frac{1}{2}$ óptimo	Sí, muy rápido
Max Weight	Bienestar global	Sí	Sí
Fuerza bruta	Configurable	Aprox.	Lento

Vamos al código...

Resultados

Datos sintéticos

- 1000 usuarios, 6 dimensiones (belleza, poder adq., extroversión, intelectualidad, aventura, romanticismo)
- Características con norma variable — algunos tienen «más de todo» ($r_{\text{norma}} = 0.92$ con atractivo recibido)
- Preferencias normalizadas (dirección pura) con componente de atractivo universal
- AUC ≈ 0.74 con Logistic Regression y Gradient Boosted Trees

Comparación principal (1000 usuarios)

Algoritmo	Pares	Peso	Tiempo	% óptimo
Gale-Shapley	500	137.8	20ms	91.2%
Greedy	500	142.9	148ms	94.6%
Max Weight	500	151.1	107s	100%
Scipy bipartito	500	151.1	13ms	100%

Comparación completa (40 usuarios)

Max Weight, Scipy y Fuerza bruta coinciden (todos óptimos); GS pierde 5%.

Algoritmo	Pares	Peso	Tiempo	% óptimo
Gale-Shapley	20	4.432	< 0.1ms	94.6%
Greedy	20	4.485	< 0.1ms	95.7%
Max Weight	20	4.687	6ms	100%
Scipy bipartito	20	4.687	< 0.1ms	100%
Fuerza bruta	20	4.687	7.3s	100%

Matchings en el grafo — Gale-Shapley

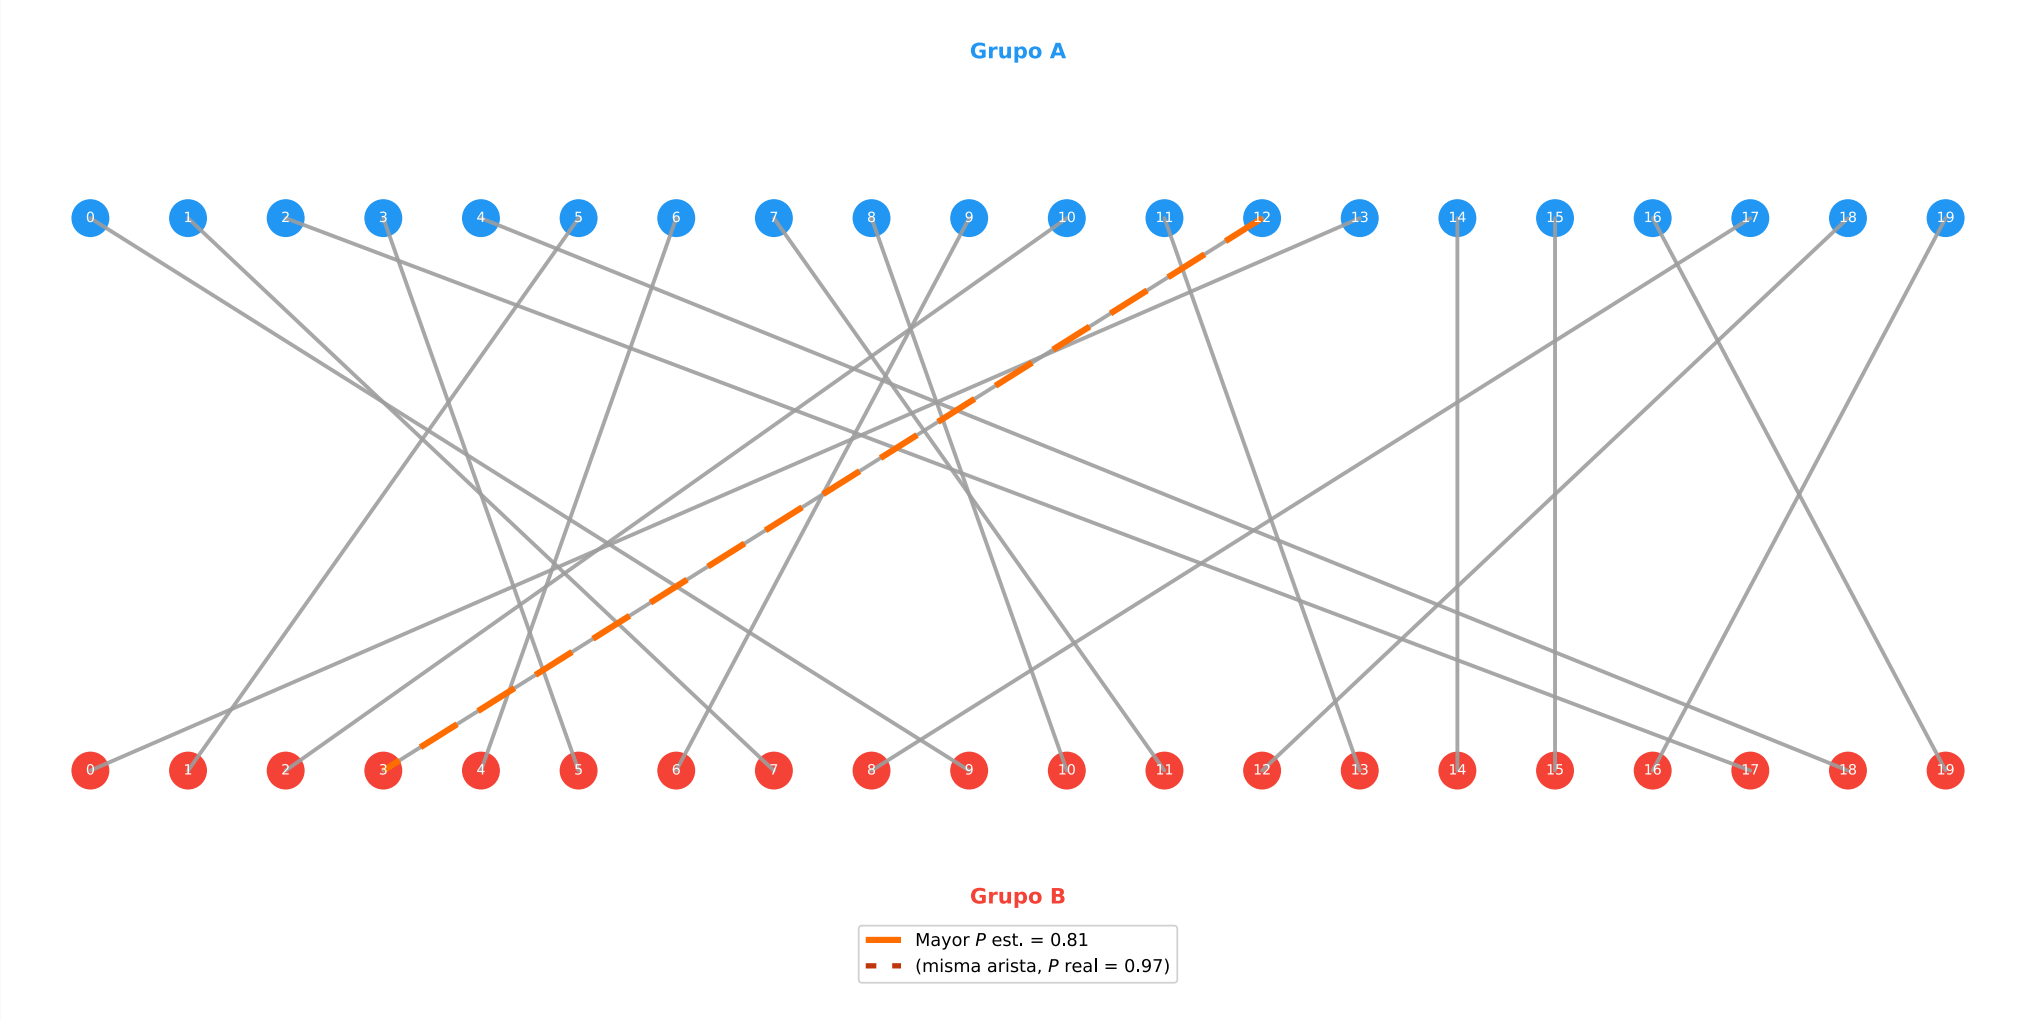

Matchings en el grafo — Greedy

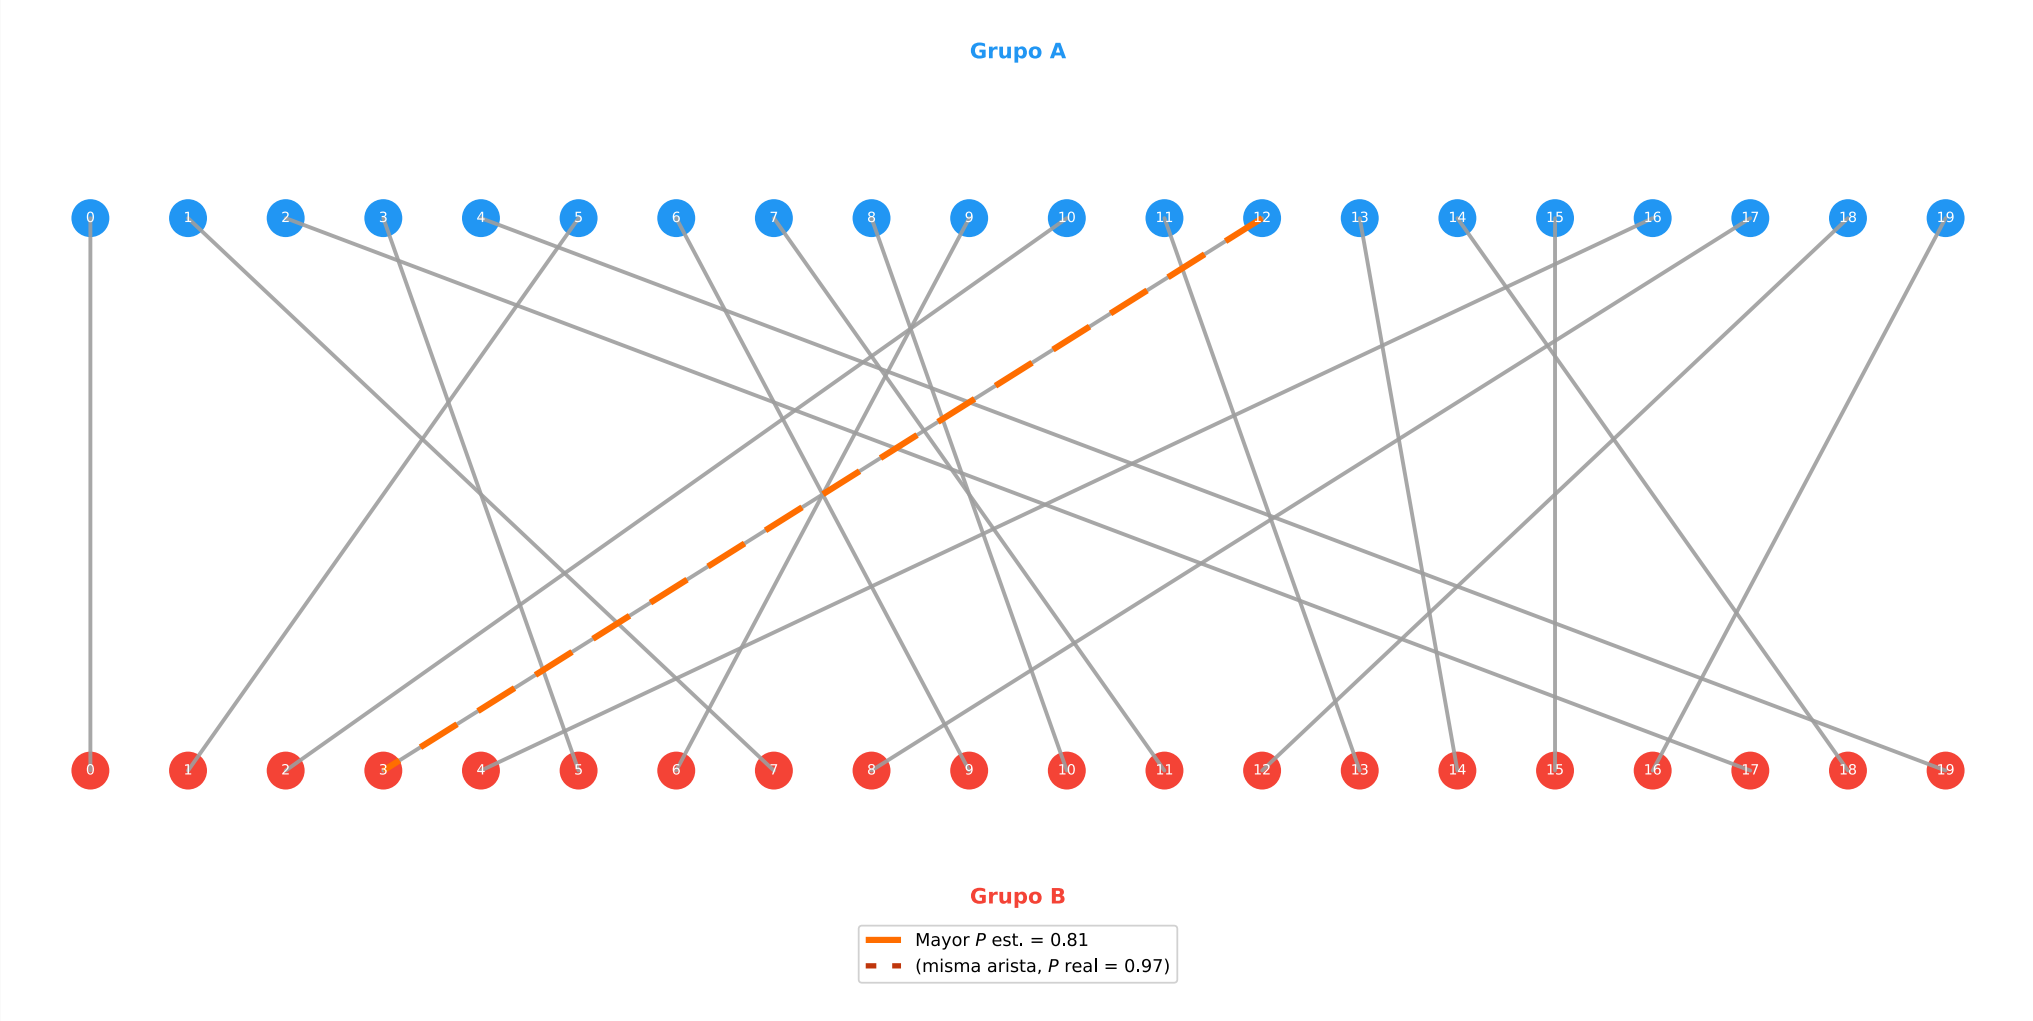

Matchings en el grafo — Max Weight

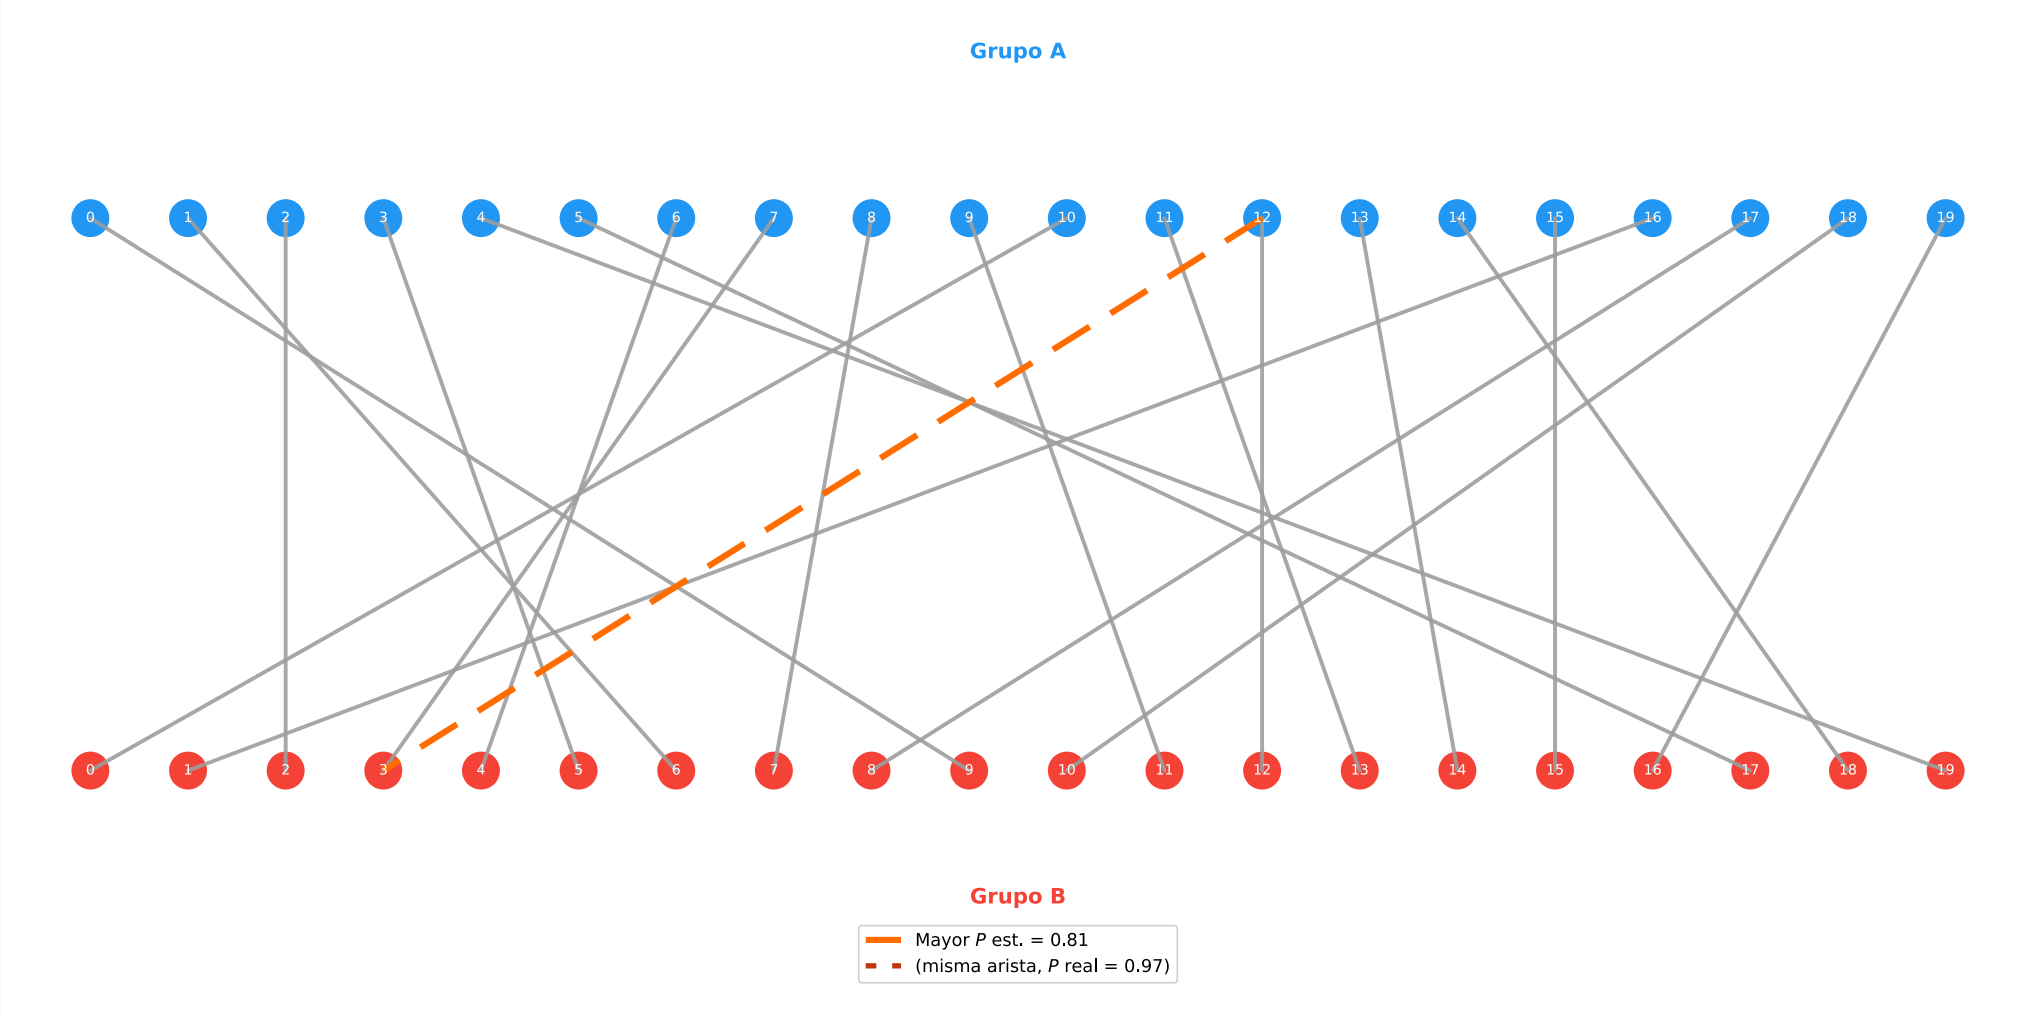

Predicciones vs. Realidad

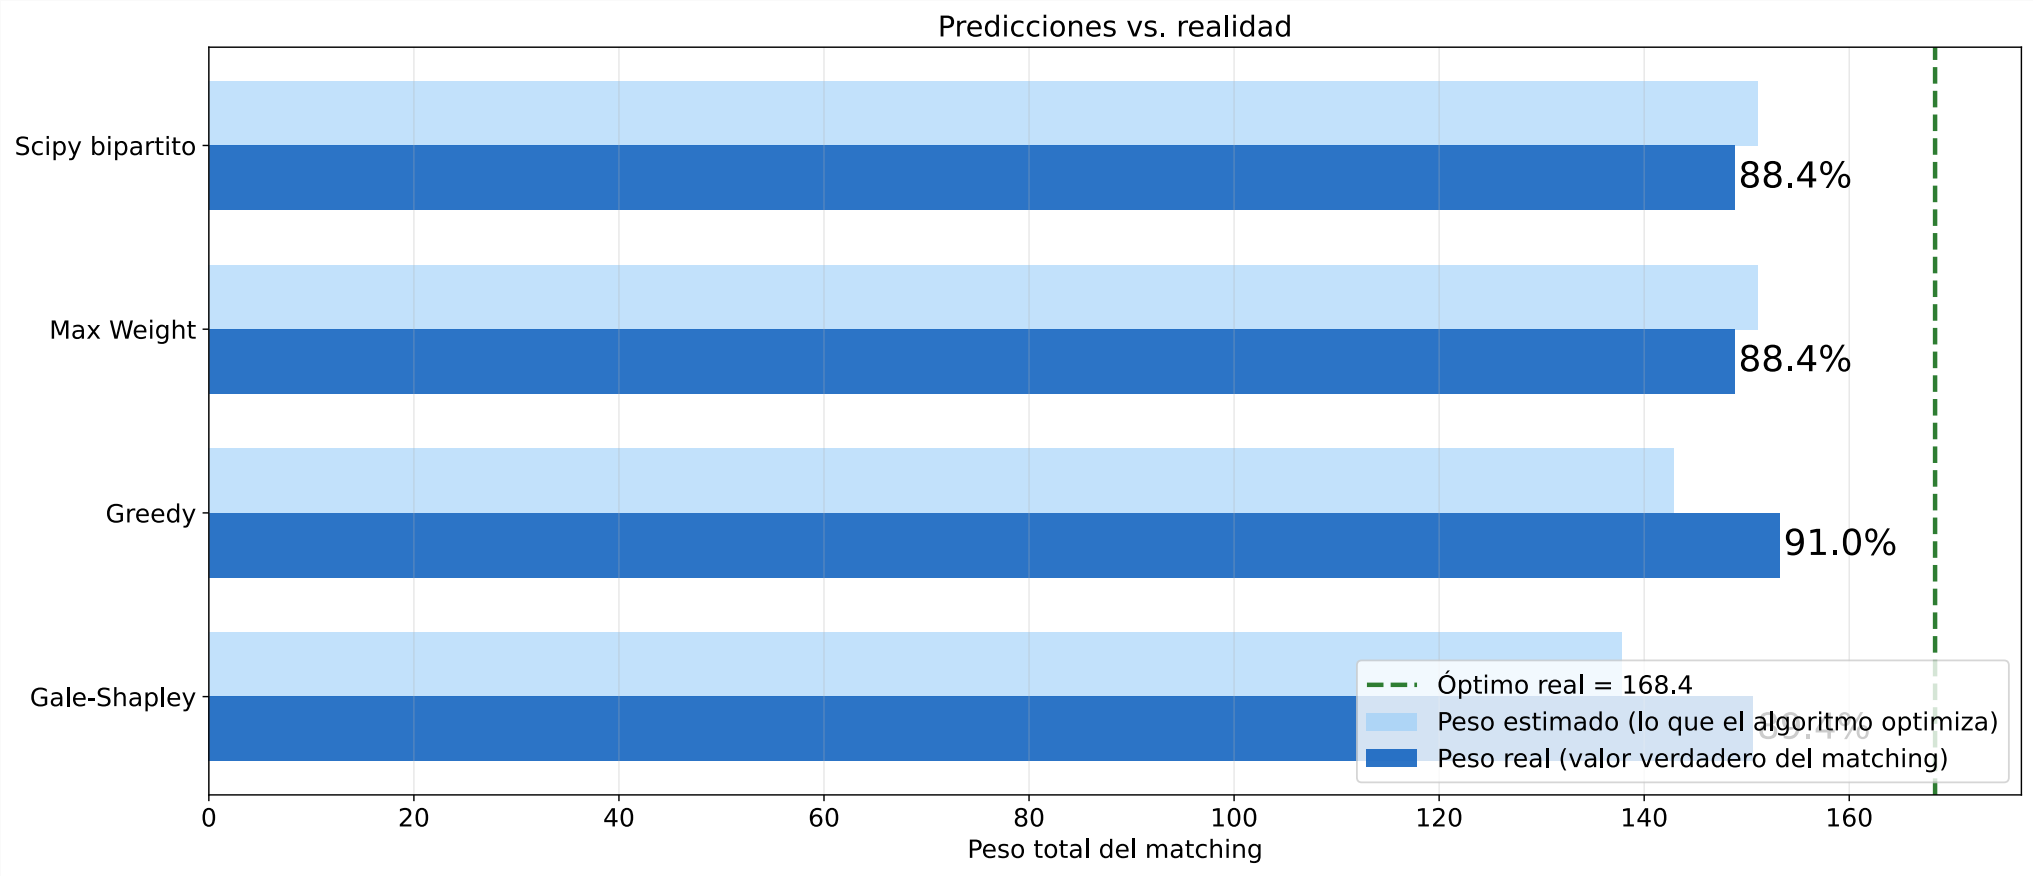

Óptimo real = lo que obtendríamos con las probabilidades verdaderas a mano (Scipy sobre P_{mut}).

Predicciones vs. Realidad

Algoritmo	Peso est.	Peso real	% óptimo
Gale-Shapley	137.8	150.6	89.4%
Greedy	142.9	153.2	91.0%
Max Weight	151.1	148.8	88.4%
Scipy bipartito	151.1	148.8	88.4%

Paradoja: Max Weight maximiza el peso *estimado* pero logra el menor peso *real*. Greedy, más conservador, supera a todos en términos efectivos.

Insights principales

1. El matching que maximiza el bienestar global puede dejar afuera al par con mayor probabilidad individual.
2. Los algoritmos más «ambiciosos» son más frágiles ante errores de estimación.

Esto es la esencia de la toma de decisiones en data science: optimizar el sistema completo, no cada componente por separado — pero siendo consciente de la calidad de nuestras estimaciones.

¡Muchas gracias!

@capitantoto

github.com/capitantoto

gonzalo-barrera-borla

Referencias

Bibliografía

Benter, W. (1994). Computer Based Horse Race Handicapping and Wagering Systems: A Report. En D. B. Hausch, V. S. Y. Lo, & W. T. Ziemba (eds.), *Efficiency of Racetrack Betting Markets: Efficiency of Racetrack Betting Markets* (pp. 183-198). Academic Press.

Box, G. E. P. (1976). Science and Statistics. *Journal of the American Statistical Association*, *71*(356), 791-799. https://doi.org/10.1080/01621459.1976.10480949

Gale, D., & Shapley, L. S. (1962). College Admissions and the Stability of Marriage. *The American Mathematical Monthly*, *69*(1), 9-15. https://doi.org/10.1080/00029890.1962.11989827

Kelly, J. L. (1956). A New Interpretation of Information Rate. *Bell System Technical Journal*, *35*(4), 917-926. https://doi.org/10.1002/j.1538--7305.1956.tb03809.x

Kuhn, H. W. (1955). The Hungarian Method for the Assignment Problem. *Naval Research Logistics Quarterly*, *2*(1–2), 83-97. https://doi.org/10.1002/nav.3800020109

Pita, C. (2019). Optimal bidding: a dual approach. *Proceedings of the 25th ACM SIGKDD Conference on Knowledge Discovery and Data Mining*, 1-6. http://papers.adkdd.org/2019/papers/adkdd19-pita-optimal.pdf